

UNSW-NB15 Üzerinde CTGAN ile Nadir Siber Saldırı Sınıfları İçin Veri Artırımı ve Karşılaştırmalı Analiz

Data Augmentation for Rare Cyber Attack Classes Using CTGAN on UNSW-NB15: A Comparative Analysis

1. Yiğit ATA

Bilgisayar Mühendisliği
Eskişehir Osmangazi Üniversitesi
Eskişehir/Türkiye
yatafb@gmail.com

2. Ad Soyad

Bölüm
Üniversite
Şehir, Ülke
e-posta adresi

Özetçe-Bu çalışmada, siber saldırı tespitinde kullanılan veri kümelerindeki dengesizlik, sınırlı örnek çeşitliliği ve veri kalitesine bağlı sorunların makine öğrenmesi modellerinin başarımı üzerindeki etkisi ele alınmaktadır. Projede, UNSW-NB15 veri kümesi kullanılarak sentetik veri üretimi ve bu verilerin saldırı tespit çalışmalarına katkısının incelenmesi amaçlanmaktadır. Bu kapsamda öncelikle veri setinin yapısı ve öznitelik özellikleri analiz edilmiş, eğitim ve test kümeleri üzerinde veri temizleme ve öznitelik mühendisliği adımları uygulanmıştır. Ardından, temel bir karşılaştırma zemini oluşturmak amacıyla ikili sınıflandırma yaklaşımıyla bir XGBoost modeli geliştirilmiştir. Elde edilen ara sonuçlarda modelin doğruluk değeri 0.9167, kesinlik değeri 0.9454, duyarlılık değeri 0.9006, F1-skoru 0.9225 ve ROC-AUC değeri 0.9775 olarak gözlemlenmiştir. Bu bulgular, uygulanan ön işleme ve öznitelik mühendisliği adımlarının etkili bir başlangıç sağladığını ve veri kümesinin sınıflandırma açısından güçlü bir temel sunduğunu göstermektedir. Çalışmanın ilerleyen aşamalarında CTGAN yöntemi ile sentetik veri üretilecek, üretilen verilerin gerçek veriyi temsil etme düzeyi incelenecek ve bu verilerin sınıflandırma performansına katkısı değerlendirilecektir.

Abstract-This study addresses the problems of data imbalance and limited sample diversity in datasets used for cyber attack detection systems. These issues are known to negatively affect the generalization performance of machine learning based classifiers, especially for underrepresented classes. The main objective of the project is to generate synthetic data using the CTGAN method on the UNSW-NB15 dataset and to examine the contribution of this generated data to the intrusion detection task. In the first stage of the study, the structure

of the dataset was analyzed in detail, and data cleaning and feature engineering processes were applied to both the training and test sets. In addition, an XGBoost model based on binary classification was developed to establish a baseline performance for comparison. The interim results show that the model provides a strong initial performance, achieving 0.9167 accuracy, 0.9225 F1-score, and 0.9775 ROC-AUC. These findings indicate that the data preprocessing stage was effective and that the impact of the synthetic data to be generated in the next stage can be evaluated in a meaningful way.

Anahtar Kelimeler

- synthetic data generation
- cybersecurity
- cyber attack detection
- intrusion detection
- UNSW-NB15
- data preprocessing
- data cleaning
- feature engineering
- class imbalance
- tabular data
- generative models
- generative adversarial networks
- GAN
- CTGAN
- machine learning
- classification
- binary classification
- XGBoost
- performance evaluation

I. GİRİŞ

Siber saldırı tespit sistemlerinde kullanılan makine öğrenmesi tabanlı yöntemlerin başarısı, büyük ölçüde eğitim verisinin kalitesine, çeşitliliğine ve sınıf dağılımına bağlıdır. Ancak mevcut siber güvenlik veri kümelerinde sıklıkla sınıf dengesizliği, az sayıda örnek içeren saldırı türleri ve sınırlı veri çeşitliliği gibi sorunlar görülmektedir. Bu problemler, modellerin özellikle düşük frekanslı saldırı sınıflarını yeterince öğrenememesine ve genelleme performansının azalmasına yol açabilmektedir. Bunun yanında gerçek siber güvenlik verilerinin elde edilmesi ve paylaşılması; maliyet, gizlilik ve erişim kısıtları nedeniyle her zaman kolay değildir. Dolayısıyla saldırı tespiti alanında dengeli, yeterli ve temsil gücü yüksek veri oluşturulması önemli bir araştırma problemi olarak öne çıkmaktadır.

Siber saldırı tespiti, bilgi sistemlerinin güvenliğinin sağlanmasında kritik bir rol oynamaktadır. Ağ trafiğinde ya da sistem davranışlarında meydana gelen zararlı faaliyetlerin doğru ve zamanında tespit edilememesi, veri ihlali, hizmet kesintisi, yetkisiz erişim ve maddi kayıp gibi ciddi sonuçlara yol açabilmektedir. Bu nedenle saldırı tespit sistemlerinde kullanılan modellerin yüksek doğrulukla çalışması kadar, farklı saldırı türlerine karşı dengeli ve güvenilir performans göstermesi de büyük önem taşımaktadır. Ancak veri kümelerindeki dengesizlik ve yetersiz temsil problemi, modellerin bazı saldırı türlerini başarılı şekilde öğrenmesini engelleyebilmektedir. Özellikle az sayıda örnek içeren saldırı sınıflarında meydana gelen başarısızlıklar, gerçek dünya uygulamalarında kritik tehditlerin gözden kaçırılmasına neden olabilir. Bu bakımdan, saldırı tespitinde kullanılan veri yapısının iyileştirilmesi ve modellerin daha sağlam biçimde eğitilebilmesi, hem akademik çalışmalar hem de pratik siber güvenlik uygulamaları açısından çözülmesi gereken önemli bir ihtiyaçtır.

Siber saldırı tespiti alanında makine öğrenmesi ve derin öğrenme tabanlı yöntemler uzun süredir yaygın olarak kullanılmaktadır. Özellikle sınıflandırma temelli modeller, ağ trafiğindeki normal ve anormal davranışların ayırt edilmesinde önemli bir araştırma alanı oluşturmuştur. Bununla birlikte literatürde, bu modellerin başarısının büyük ölçüde kullanılan veri kümelerinin kalitesine ve dağılımına bağlı olduğu vurgulanmaktadır. Son yıllarda veri dengesizliği ve sınırlı örnek çeşitliliği problemlerine çözüm üretmek amacıyla sentetik veri üretimi yaklaşımlarına olan ilgi artmıştır. Bu kapsamda üretken çekişmeli ağlar (GAN) ve özellikle tablosal veriler için geliştirilen CTGAN gibi yöntemler, gerçek veri dağılımını taklit edebilen yeni örnekler üretme potansiyeli nedeniyle dikkat çekmektedir. Siber güvenlik alanında da sentetik veri kullanımının, az temsil edilen saldırı türlerinin desteklenmesi ve veri artırma sürecinin güçlendirilmesi açısından umut verici bir yaklaşım olduğu değerlendirilmektedir. Bu nedenle, CTGAN tabanlı sentetik veri üretiminin saldırı tespiti bağlamında incelenmesi, güncel literatürde anlamlı bir araştırma doğrultusuna karşılık gelmektedir.

Mevcut çözümler, siber saldırı tespiti alanında önemli ilerlemeler sağlamış olsa da veri kaynaklı temel problemlere

her zaman yeterli çözüm sunamamaktadır. Geleneksel makine öğrenmesi modelleri çoğu zaman mevcut veri kümesinin dağılımına bağımlı biçimde öğrenmekte, bu nedenle dengesiz veri yapılarında çoğunluk sınıflarına karşı daha başarılı olurken az temsil edilen saldırı türlerinde daha düşük performans gösterebilmektedir. Bunun yanında gerçek siber güvenlik verilerinin toplanması ve etiketlenmesi zaman alıcı, maliyetli ve gizlilik açısından sınırlayıcı bir süreçtir. Klasik veri artırma yöntemleri ise özellikle tablosal verilerde gerçek veri dağılımını yeterince yansıtmakta yetersiz kalabilmektedir. Bu nedenle yalnızca mevcut veriyle model eğitmek ya da sınırlı veri artırma tekniklerine başvurmak, saldırı tespitinde ihtiyaç duyulan temsil gücünü ve genelleme başarımını her zaman sağlayamamaktadır. Bu noktada, gerçek verinin yapısal özelliklerini koruyarak yeni örnekler üretebilen üretken modeller, mevcut yaklaşımlardaki bu boşluğu giderebilecek güçlü bir alternatif olarak öne çıkmaktadır.

Bu çalışmada, siber saldırı tespiti alanında veri dengesizliği ve sınırlı örnek çeşitliliği problemlerine yönelik olarak CTGAN tabanlı sentetik veri üretimi yaklaşımı ele alınmaktadır. Proje kapsamında UNSW-NB15 veri kümesi üzerinde veri temizleme, ön işleme ve öznitelik mühendisliği adımları uygulanmış, ardından başlangıç düzeyinde bir karşılaştırma zemini oluşturmak amacıyla ikili sınıflandırma temelli bir XGBoost modeli geliştirilmiştir. Elde edilen ara sonuçlar, kurulan temel modelin güçlü bir başlangıç performansı sunduğunu göstermektedir. Çalışmanın temel katkısı, tablosal siber güvenlik verileri üzerinde CTGAN kullanılarak üretilen sentetik örneklerin gerçek veri yapısını ne ölçüde temsil ettiğini incelemek ve bu verilerin saldırı tespit performansına sağlayacağı katkısı değerlendirmektir. Bu yönüyle proje, hem veri artırma yaklaşımının siber güvenlik bağlamındaki uygulanabilirliğini analiz etmeyi hem de gelecekte daha dengeli ve daha temsil gücü yüksek veri kümeleri ile daha başarılı saldırı tespit modelleri geliştirilmesine katkı sunmayı amaçlamaktadır.

II. İlgili Çalışmalar (Related Work)

A) Efficient Intrusion Detection: Combining χ^2 Feature Selection with CNN-BiLSTM on the UNSW-NB15 Dataset [1]

Bu çalışmada, UNSW-NB15 veri seti kullanılarak chi-square tabanlı öznitelik seçimi ile CNN-BiLSTM tabanlı hibrit bir saldırı tespit modeli önerilmiştir. Çalışmanın temel amacı, özellikle kaynak kısıtlı ortamlarda yüksek doğruluk sağlarken model karmaşıklığını azaltmaktır. Elde edilen sonuçlar, öznitelik seçimi ile desteklenen derin öğrenme mimarisinin intrusion detection alanında etkili olduğunu göstermektedir. Ancak çalışmada sentetik veri üretimi veya CTGAN tabanlı veri artırma yaklaşımı yer almamaktadır. Bu nedenle çalışma, aynı veri seti üzerinde farklı bir çözüm yaklaşımı sunması bakımından önemlidir.

B) Evaluating the Performance of Classification Algorithms on the UNSW-NB15 Dataset for Network Intrusion Detection [2]

Bu çalışmada, UNSW-NB15 veri seti üzerinde farklı makine öğrenmesi algoritmalarının ikili sınıflandırma performansları incelenmiştir. Araştırmada veri temizleme, kategorik değişken kodlama, normalizasyon ve sınıf dengesizliğini azaltmak amacıyla SMOTE ile undersampling birlikte uygulanmıştır. Ardından k-NN, Naive Bayes, Logistic Regression, SVM ve Neural Network gibi modeller karşılaştırılmıştır. Çalışma, klasik makine öğrenmesi modelleri ile geleneksel veri dengeleme yöntemlerinin intrusion detection üzerindeki etkisini göstermesi bakımından önemlidir. Ancak üretken model tabanlı bir veri artırma yaklaşımı sunmamaktadır.

C) Intrusion Detection on the UNSW-NB15 Dataset Using Feature Selection and Machine Learning Techniques [3]

Bu çalışmada, UNSW-NB15 veri seti üzerinde öznitelik seçimi ve makine öğrenmesi teknikleri kullanılarak saldırı tespiti gerçekleştirilmiştir. Araştırmada uygun özniteliklerin seçilmesinin hem sınıflandırma başarımını artırdığı hem de hesaplama maliyetini azalttığı vurgulanmaktadır. Çalışma, intrusion detection alanında feature selection kullanımının önemini ortaya koymaktadır. Bununla birlikte, veri dengesizliği ve sınırlı örnek çeşitliliği problemi sentetik veri üretimiyle değil, öznitelik indirgeme ve sınıflandırıcı performansı üzerinden ele alınmıştır.

D) Network Based Intrusion Detection Using the UNSW-NB15 Dataset [4]

Bu çalışmada, UNSW-NB15 veri seti üzerinde iki aşamalı bir anomali tabanlı saldırı tespit yaklaşımı önerilmiştir. İlk aşamada öznitelik seçimi uygulanmış, ardından ikili sınıflandırma ile saldırı ve normal trafik ayrımı yapılmış, ikinci aşamada ise saldırı türlerinin belirlenmesine yönelik çok sınıflı sınıflandırma gerçekleştirilmiştir. Çalışma, UNSW-NB15 veri seti üzerinde uygulanan klasik intrusion detection akışlarını göstermesi bakımından önemlidir. Ancak üretken modeller veya sentetik veri üretimi araştırmanın kapsamı içinde yer almamaktadır.

E) Generative Adversarial Nets [6]

Bu çalışma, üretken çekişmeli ağlar yaklaşımını ilk ortaya koyan temel çalışmadır. GAN yapısı, bir üretici ve bir ayırt edici ağın çekişmeli biçimde eğitilmesine dayanmakta ve gerçek veri dağılımına benzer yeni örnekler üretmeyi amaçlamaktadır. Daha sonra geliştirilen TGAN, CTGAN ve benzeri tablosal sentetik veri üretim yaklaşımlarının kuramsal temeli bu çalışmaya dayanmaktadır. Bu nedenle çalışma, sentetik veri üretimi odaklı intrusion detection araştırmalarının teorik altyapısını oluşturan temel bir kaynaktır.

F) An Analysis of the KDD99 and UNSW-NB15 Datasets for the Intrusion Detection System [5]

Bu çalışmada, KDD99 ve UNSW-NB15 veri setleri sınıf dağılımı, tekrar eden kayıtlar, öznitelik yapısı ve intrusion detection çalışmalarına uygunluk açısından ayrıntılı biçimde incelenmiştir. Araştırma, özellikle veri setlerinin dengesiz yapısını ve öznitelik özelliklerini ortaya koyması bakımından önemlidir. Her ne kadar doğrudan bir sentetik veri üretim modeli önermese de, veri seti seçiminin akademik olarak gerektendirilmesi açısından güçlü bir kaynak niteliğindedir.

G) Machine Learning for Network Attacks Classification and Statistical Evaluation of Adversarial Learning Methodologies for Synthetic Data Generation [10]

Bu çalışma, ağ saldırılarının sınıflandırılması ile sentetik veri üretiminin istatistiksel değerlendirmesini bir araya getirmektedir. Araştırmada üretilen veriler yalnızca sınıflandırma başarımı açısından değil, fidelity, utility ve privacy boyutlarında da incelenmiştir. Bu yönüyle çalışma, sentetik veri üretiminin daha kapsamlı değerlendirilmesi gerektiğini göstermektedir. Ancak veri seti ve deney düzeni mevcut çalışmadan farklı olduğu için, daha çok güncel eğilimleri destekleyen bir kaynak olarak değerlendirilebilir.

H) FS-TGAN: An Enhanced Approach for Internet of Things Intrusion Detection System Based on Feature Selection and Tabular Generative Adversarial Network [7]

Bu çalışmada, UNSW-NB15 veri seti üzerinde sınıf dengesizliği problemini çözmek amacıyla feature selection ile TGAN tabanlı bir intrusion detection yaklaşımı önerilmiştir. Ayrıca sonuçlar SMOTE ve ADASYN gibi geleneksel veri artırma yöntemleriyle karşılaştırılmıştır. Elde edilen bulgular, TGAN tabanlı yaklaşımın doğruluk ve F1-skoru bakımından klasik yöntemlere göre daha başarılı olduğunu göstermektedir. Ancak çalışmada CTGAN yerine TGAN tercih edilmiştir.

I) Generating Synthetic Dataset for ML-Based IDS Using CTGAN and Feature Selection to Protect Smart IoT Environments [8]

Bu çalışmada, intrusion detection sistemleri için sentetik veri üretmek amacıyla CTGAN tabanlı bir yaklaşım önerilmiş ve üretilen veri kümesinin istatistiksel ve makine öğrenmesi tabanlı metriklerle geçerliliği incelenmiştir. Araştırmada ayrıca feature selection yöntemleri ile model karmaşıklığının azaltılması hedeflenmiştir. Train on synthetic, test on real yaklaşımının kullanılması, sentetik verinin gerçek verinin yerine kullanılabilirliğini değerlendirmesi bakımından dikkat çekicidir. Bu çalışma, CTGAN'ın intrusion detection alanında uygulanabilirliğini göstermesi nedeniyle mevcut projeye oldukça yakın bir örnektir.

J) Enhanced Intrusion Detection Using Conditional-Tabular-Generative-Adversarial-Network-Augmented Data and a Convolutional Neural Network: A Robust Approach to Addressing Imbalanced Cybersecurity Datasets [9]

Bu çalışmada, NSL-KDD ve UNSW-NB15 veri setleri üzerinde CTGAN tabanlı veri artırımı kullanılarak intrusion detection performansının artırılması amaçlanmıştır. Araştırmada özellikle SMOTE gibi geleneksel veri dengeleme yöntemlerinin sınırlılıkları vurgulanmış, buna karşılık CTGAN'ın veri dağılımını daha iyi koruyabilen bir yaklaşım sunduğu belirtilmiştir. Üretilen dengeli veri kümesi CNN tabanlı sınıflandırıcı ile değerlendirilmiş ve intrusion detection başarımında iyileşme raporlanmıştır. Bu çalışma, veri dengesizliği problemini doğrudan CTGAN ile ele alması bakımından mevcut projeye en yakın çalışmalardan biridir.


III. YÖNTEM (METODOLOJİ)

Bu çalışmada, siber saldırı tespiti için UNSW-NB15 veri seti kullanılmıştır. Eğitim ve test kümeleri ayrı ele alınmış, her iki küme üzerinde veri temizleme ve öznitelik mühendisliği adımları uygulanmıştır. Bu süreçte veri yapısı incelenmiş, sınıflandırmayı olumsuz etkileyebilecek alanlar düzenlenmiş ve modelleme için uygun veri yapısı hazırlanmıştır.

Başlangıç performansını belirlemek amacıyla ikili sınıflandırma temelli bir XGBoost modeli kurulmuştur. XGBoost, tablosal veriler üzerindeki güçlü performansı nedeniyle tercih edilmiştir. Elde edilen ara sonuçlarda modelin yüksek doğruluk ve F1-skoru ile düşük yanlış alarm oranı ürettiği görülmüştür. Bu nedenle çalışma için temel karşılaştırma modeli olarak seçilmiştir.

Sonraki aşamada, tablosal sentetik veri üretimi için CTGAN kullanılacaktır. Bu model ile özellikle az temsil edilen saldırı sınıfları desteklenecek ve sentetik verinin sınıflandırma başarımına etkisi incelenecektir. Metinde yer verilen görseller, bu çalışmada elde edilen çıktılar değil, literatürde benzer yaklaşımları açıklamak amacıyla kullanılan örnek görsellerdir.

Şekil 1. Örnek bir veri dağılımı görselleştirmesi.[11]



MODEL	ACCURACY		F1-SCORE		FALSE ALARM RATE	
	TRAIN	VALIDATION	TRAIN	VALIDATION	TRAIN	VALIDATION
LOGISTIC REGRESSION	0.9052	0.9021	0.9544	0.9534	0.0947	0.0978
K-NEAREST NEIGHBORS	0.9173	0.9100	0.9591	0.9554	0.0826	0.0899
DECISION TREE	0.8926	0.8882	0.9517	0.9500	0.1073	0.1117
RANDOM FOREST	0.9143	0.9028	0.9612	0.9560	0.0856	0.0971
XGBOOST	0.9669	0.9391	0.9819	0.9665	0.0330	0.0608

Şekil 2. Örnek model performans karşılaştırması.[11]

IV. Ara Sonuçlar (Preliminary Results)

Bu çalışmada, şimdiye kadar öncelikle UNSW-NB15 veri setinin yapısı incelenmiş, eğitim ve test kümeleri üzerinde veri temizleme ve öznitelik mühendisliği adımları uygulanmıştır. Ardından, sentetik veri üretimi aşamasına geçmeden önce güçlü bir başlangıç karşılaştırma zemini oluşturmak amacıyla ikili sınıflandırma temelli bir XGBoost modeli geliştirilmiştir. Yapılan ilk deneylerde, 0.9 eşik değeri altında modelin doğruluk değeri 0.9167, precision değeri 0.9454, recall değeri 0.9006, specificity değeri 0.9363 ve F1-skoru 0.9225 olarak elde edilmiştir. Ayrıca false positive rate 0.0637, false negative rate 0.0994, ROC-AUC değeri 0.9775 ve average precision değeri 0.9839 olarak hesaplanmıştır. Bu ara sonuçlar, uygulanan ön işleme sürecinin etkili olduğunu ve kurulan XGBoost modelinin, çalışmanın sonraki aşamasında CTGAN ile üretilen sentetik verilerin katkısını değerlendirmek için güçlü bir baseline oluşturduğunu göstermektedir.

V. Tartışma (Discussion)

Bu aşamada elde edilen sonuçlar umut verici olsa da çalışma henüz başlangıç düzeyindedir. XGBoost modelinin ikili sınıflandırmada 0.9167 doğruluk, 0.9225 F1-skoru ve 0.9775 ROC-AUC değeri üretmesi, veri ön işleme ve öznitelik mühendisliği adımlarının etkili olduğunu göstermektedir. Bununla birlikte, mevcut değerlendirme yalnızca binary sınıflandırma düzeyinde gerçekleştirilmiştir; bu nedenle modelin farklı saldırı türlerini birbirinden ayırma başarısı henüz test edilmemiştir. Özellikle UNSW-NB15 veri setinin dengesiz yapısı ve bazı saldırı sınıflarının düşük temsil edilmesi dikkate alındığında, multiclass aşamasına geçildiğinde performansın aynı düzeyde kalmama olasılığı bulunmaktadır. Ayrıca karar eşiği seçiminin precision, recall ve F1-skoru üzerinde belirgin etkisi olduğu görülmüş, bu durum model başarısının yalnızca algoritmaya değil, değerlendirme stratejisine de bağlı olduğunu göstermiştir. Mevcut aşamada CTGAN ile sentetik veri üretimi henüz tamamlanmadığından, özellikle az temsil edilen sınıflarda veri artırmanın sağlayacağı katkı doğrudan gözlemlenememiştir. Bu nedenle şu anki sonuçlar güçlü bir baseline sunsa da, çalışmanın asıl katkısı multiclass değerlendirme ve sentetik veri destekli karşılaştırmalar tamamlandığında daha net biçimde ortaya çıkacaktır.

VI. Gelecek Çalışmalar (Future Work)

Çalışmanın sonraki aşamalarında, mevcut binary sınıflandırma yapısından multiclass yapıya geçilerek farklı saldırı türlerinin

ayrı ayrı tespit edilmesi hedeflenmektedir. Ayrıca CTGAN modeli kullanılarak özellikle az temsil edilen saldırı sınıfları için sentetik veri üretilecek ve bu verilerin sınıflandırma performansına katkısı karşılaştırmalı olarak değerlendirilecektir. Bunun yanında, daha gelişmiş öznitelik mühendisliği ve hiperparametre iyileştirme adımları uygulanarak mevcut doğruluk, F1-skoru ve diğer başarı ölçütlerinin artırılması amaçlanmaktadır. Veri setindeki düzensiz, dengesiz veya problemli kayıtların daha sistematik biçimde düzenlenmesiyle daha temiz ve daha büyük veri yapıları üzerinde çalışılması da planlanmaktadır. Bu doğrultuda, hem veri kalitesinin hem de modelin genelleme başarısının artırılması, çalışmanın gelecekteki temel geliştirme yönlerini oluşturmaktadır.

VII. Sonuç (Conclusion)

Bu ara rapor kapsamında, UNSW-NB15 veri seti üzerinde veri temizleme ve öznitelik mühendisliği adımları tamamlanmış, ardından gerçek veri üzerinde güçlü bir başlangıç karşılaştırması elde etmek amacıyla ikili sınıflandırma temelli bir XGBoost modeli geliştirilmiştir. Elde edilen ara sonuçlarda modelin 0.9167 doğruluk, 0.9454 precision, 0.9006 recall, 0.9363 specificity, 0.9225 F1-skoru, 0.9775 ROC-AUC ve 0.9839 average precision değerlerine ulaştığı görülmüştür. Bu bulgular, projenin veri hazırlama ve başlangıç modelleme aşamasının başarılı biçimde tamamlandığını ve çalışmanın temel hedefi doğrultusunda güçlü bir baseline oluşturulduğunu göstermektedir. Bununla birlikte, projenin asıl amacı olan CTGAN ile sentetik veri üretimi, multiclass sınıflandırma ve özellikle az temsil edilen saldırı sınıflarındaki performans artışının değerlendirilmesi henüz tamamlanmamıştır. Dolayısıyla proje hedefi kısmen gerçekleştirilmiş olup, mevcut aşamada veri hazırlama ve temel sınıflandırma altyapısı başarıyla kurulmuş, sonraki aşamalar için sağlam bir deney zemini oluşturulmuştur.

KAYNAKLAR

- [1] Y. Wang, P. Wang, J. Pei, Y. Li, and Y. Zhang, "Efficient Intrusion Detection: Combining χ^2 Feature Selection with CNN-BiLSTM on the UNSW-NB15 Dataset," *IEEE Access*, 2024.
- [2] Z. P. Putra, "Evaluating the Performance of Classification Algorithms on the UNSW-NB15 Dataset for Network Intrusion Detection," *Jurnal Ilmiah FIFO*, vol. 16, no. 1, pp. 84–95, May 2024.
- [3] J. V. Rosy and S. B. Ramesh Kumar, "Intrusion Detection on the UNSW-NB15 Dataset Using Feature Selection and Machine Learning Techniques," *Webology*, vol. 18, no. 6, 2021.
- [4] S. Meftah, T. Rachidi, and N. Assem, "Network Based Intrusion Detection Using the UNSW-NB15 Dataset," *International Journal of Computing and Digital Systems*, vol. 8, no. 5, pp. 477–487, Sep. 2019.
- [5] M. S. Al-Daweri, K. A. Z. Ariffin, S. Abdullah, and M. F. E. Md. Senan, "An Analysis of the KDD99 and UNSW-NB15

Datasets for the Intrusion Detection System," *Symmetry*, vol. 12, no. 10, p. 1666, 2020.

- [6] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative Adversarial Nets," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2014, pp. 2672–2680.
- [7] FS-TGAN: An Enhanced Approach for Internet of Things (IoT) Intrusion Detection System Based on Feature Selection and Tabular Generative Adversarial Network, SSRN preprint, 2023.
- [8] S. Alabdulwahab, Y.-T. Kim, A. Seo, and Y. Son, "Generating Synthetic Dataset for ML-Based IDS Using CTGAN and Feature Selection to Protect Smart IoT Environments," *Applied Sciences*, vol. 13, no. 19, p. 10951, 2023.
- [9] S. Allagi, T. Pawan, and W. Y. Leong, "Enhanced Intrusion Detection Using Conditional-Tabular-Generative-Adversarial-Network-Augmented Data and a Convolutional Neural Network: A Robust Approach to Addressing Imbalanced Cybersecurity Datasets," *Mathematics*, vol. 13, no. 12, p. 1923, 2025.
- [10] I.-C. Zarkadis and C. Douligeris, "Machine Learning for Network Attacks Classification and Statistical Evaluation of Adversarial Learning Methodologies for Synthetic Data Generation," *arXiv preprint arXiv:2603.17717*, 2026.
- [11] <https://github.com/Hashehri/Network-Traffic-Classification-UNSW-NB15>
- [12] https://github.com/adamsxs/metis_project_05_anomaly_detection