

Normal Retina OCT Goruntulerinden Ogrenilen
Konvolusyonel Autoencoder ile Patolojik Orneklerin
Rekonstruksiyon Hatası Tabanlı Tespiti
Reconstruction-Error-Based Detection of Pathological Retinal
OCT Scans Using a Convolutional Autoencoder Trained on
Normal Images

Yazar 1 - Bilgisayar Muhendisligi - Universite - e-posta
Yazar 2 - Bilgisayar Muhendisligi - Universite - e-posta

I. BASLIK

Ingilizce baslik: Reconstruction-Error-Based Detection of
Pathological Retinal OCT Scans Using a Convolutional
Autoencoder Trained on Normal Images

II. OZET

Bu calismada, retinal OCT görüntülerinde patolojik örnekleri etiketlenmiş patoloji sınıflarıyla doğrudan öğrenmek yerine, yalnızca normal örneklerden öğrenilen bir convolutional autoencoder ile reconstruction error tabanlı anomaly detection yaklaşımı geliştirilmiştir. Kermany OCT2017 veri kumesindeki train/NORMAL görüntüleri hasta bazlı olarak eğitim ve validation alt kumelerine ayrılmış, model yalnızca normal anatominin dağılımını öğrenmiştir. Test aşamasında NORMAL, CNV, DME ve DRUSEN görüntüleri reconstruction error ile puanlanmış ve validation normal error dağılımından elde edilen percentil esikleriyle ikili karar üretilmiştir. Bu ara rapor surumunde temel model 128x128 gri tonlamalı B-scan'ler üzerinde eğitilmiş, AUROC ana metrik olarak alınmış ve precision, recall, F1, accuracy ile FPR de raporlanmıştır. Gerçek OCT2017 deneyi sonunda seçilen p95 esiginde AUROC 0.9108 ve F1 0.8201 elde edilmiştir. Elde edilen ilk bulgular, patolojik sınıfların ortalama reconstruction error değerlerinin normal sınıfa göre sistematik olarak daha yüksek olduğunu göstermektedir.

III. ABSTRACT

This study investigates reconstruction-error-based anomaly detection for retinal OCT images using a convolutional autoencoder trained only on normal samples. Instead of learning a supervised pathology classifier, the model learns the appearance distribution of healthy retinal anatomy from the Kermany OCT2017 dataset. The training split uses only normal scans and a patient-level validation split is used to estimate operating thresholds from normal reconstruction-error percentiles. During testing, NORMAL, CNV, DME, and DRUSEN scans are scored according to reconstruction error, and anomaly decisions are produced with validation-derived thresholds. On the real OCT2017 experiment, the selected p95 operating point reaches AUROC 0.9108 and F1-score 0.8201. These findings indicate that a normal-only autoencoder can

serve as a meaningful early baseline for retinal anomaly screening.

IV. ANAHTAR KELİMELER / KEYWORDS

retinal OCT, anomaly detection, autoencoder, reconstruction error, medical imaging, deep learning

V. 1. GİRİŞ

Retinal hastalıkların erken tespiti, geri donulmez görme kaybını azaltmak için kritik önemdedir. Optik koherens tomografi (OCT), retina tabakalarını yüksek çözünürlükte gösterebildiği için klinik pratikte sık kullanılan bir görüntüleme yöntemidir. Ancak OCT verisinin elle yorumlanması zaman alıcı olduğu gibi, geniş tarama programlarında yüksek uzman emeği gerektirir [1]. Son yıllarda derin öğrenme tabanlı denetimli modeller OCT sınıflandırmasında güçlü sonuçlar vermiş olsa da, bunlar genellikle her patoloji için etiketli veri gerektirir [1], [3]. Bu durum, daha önce görülmemiş veya yeterince temsil edilmeyen anomalilerin tespitini zorlaştırır.

Bu projede problem, normal anatominin öğrenilmesi ve ondan sapmaların reconstruction error ile yakalanması olarak ele alınmıştır. Ara rapor kapsamındaki amacımız, yalnızca normal retina OCT görüntüleri ile eğitilen bir convolutional autoencoder'in patolojik test görüntülerini anlamlı biçimde ayırtılabildiğini gösteren, tekrar üretilebilir bir baseline sistem kurmaktır. Bu çalışmanın farkı; patient-level validation, validation-derived threshold seçimi ve gerçek OCT verisiyle uctan uca çalışan deney boru hattını aynı raporda birleştirmesidir.

VI. 2. İLGİLİ ÇALIŞMALAR

OCT alanında derin öğrenme tabanlı hastalık sınıflandırması için en çok atıf alan çalışmalardan biri Kermany ve ark. tarafından sunulan Cell 2018 makalesidir [1]. Bu çalışma, aynı zamanda bu projede kullanılan halka açık OCT veri kumesinin temellerini de oluşturmaktadır [2]. Literatürde bunun devamında çok sayıda denetimli retinal hastalık tespit modeli önerilmiş ve OCT'nin otomatik analiz için uygunluğu güçlü biçimde ortaya konmuştur [3].

Anomaly detection literatüründe ise normal veriyle eğitim yapıp anomalileri dağılım dışı örnekler olarak ele alan reconstructive ve adversarial yöntemler ön plana çıkmıştır. AnoGAN [4] ve GANomaly [5] gibi yaklaşımlar normal dağılımı modelleme mantığını sistematikleştirmiştir. DRAEM [6] ve ProxyAno [8] ise reconstruction tabanlı yapıların daha ayırt edici hale gelmesine odaklanmıştır. Retinal OCT özelinde Seebock ve ark. [7], Luo ve ark. [9] ve Wang ve ark. [10] gibi çalışmalar bu alanın artık yalnızca genel anomaly

detection degil, retina anatomisine ozel cozumler de gerektirdigini gostermektedir.

Kim ne yapmis ve bu proje neyi farkli yapıyor sorusunu daha acik gostermek icin Tablo 1 verilmiştir.

Tablo 1. Ilgili calismalar ve bu projeden farklari.

study	focus	difference
Kermany et al. [1]	Supervised OCT classification	Requires pathology labels, unlike our normal-only anomaly setting.
AnoGAN [4]	GAN-based anomaly detection	General anomaly detection reference, not retinal OCT-specific.
Seebock et al. [7]	Uncertainty-based OCT anomaly detection	Uses anatomy segmentation uncertainty instead of direct reconstruction error.
Luo et al. [9]	Multi-resolution retinal autoencoder	More advanced retinal anomaly model; our work is a simpler reproducible baseline.
This project	Normal-only OCT anomaly scoring	Patient-level validation split and percentile-based threshold selection on real OCT2017.

VII. 3. YONTEM

A. 3.1 Veri kumesi ve bolme stratejisi

Calismada Kermany OCT2017 veri kumesinin 'train' ve 'test' klasorleri esas alınmıştır [2]. Egitimde yalnızca 'train/NORMAL' altındaki görüntüler kullanılmıştır. Validation bolmesi image-level degil patient-level olarak yapılmıştır; böylece ayni hastaya ait görüntüler train ve validation alt kumelerine ayni anda dusememiştir. Test asamasında 'test/NORMAL', 'test/CNV', 'test/DME' ve 'test/DRUSEN' görüntüleri birlikte degerlendirilmiş, NORMAL sinifi 0 ve diger tum siniflar anomaly etiketi 1 olarak ele alınmıştır.

B. 3.2 On isleme

Tum görüntüler tek kanalli gri tonlamaya donusturulmus, '128x128' boyutuna yeniden orneklenmis ve '[0, 1]' araligina normalize edilmistir. Bu ara surumde agresif augmentation

uygulanmamistir; amacimiz once sade ve tekrarlanabilir bir baseline kurmaktır.

C. 3.3 Model mimarisi

Model, dort asamali bir convolutional encoder-decoder yapisindan olusmaktadır. Encoder kismi 1->32->64->128->256 kanal gecisleri ve max-pooling adimlariyla goruntuyu sikistirirken, ara latent temsil '128' boyutlu bir vektore indirgenmiştir. Decoder kismi transpose convolution bloklari ile goruntuyu tekrar 128x128 boyutuna tasimaktadır. Cikis katmanında sigmoid kullanılarak normalize pikseller üzerinde reconstruction uretilmiştir.

D. 3.4 Egitim ve esikleme

Model 'Adam' optimizer ve 'MSE' reconstruction loss ile egitilmiştir. En fazla '40' epoch ve '8' patience degerli early stopping kullanılmıştır. Validation asamasında yalnızca normal orneklerin reconstruction error dagilimi incelenmiş; p95, p97 ve p99 esikleri hesaplanmıştır. Ana operasyon noktası olarak p95 secilmiştir. Boylece threshold seciminde test verisi kullanılmamis ve leakage engellenmiştir.

E. 3.5 Degerlendirme olcutleri ve deney kurulumu

Ana basari olcutu olarak AUROC secilmiştir; cunku anomaly detection senaryosunda threshold'dan bagimsiz ayristirma gucunu yansitir. Bunun yanında accuracy, precision, recall, F1 ve false positive rate de raporlanmıştır. Precision ve recall birlikte yorumlanmış, F1 ise dengeli operasyon noktası seciminde kullanılmıştır. Gercek deney kosusu yaklaşık 109.7 dakika surmus ve en iyi validation sonucu 37. epoch'ta elde edilmiştir. Deney kurulumu Tablo 2'de ozetlenmiştir.

Tablo 2. Deney kurulumu ve temel hiperparametreler.

setting	value
Train data	40715 NORMAL images
Validation data	10425 NORMAL images
Test data	1000 images
Input size	128x128 grayscale
Latent dimension	128
Optimizer	Adam, lr=0.001
Max epochs / patience	40 / 8
Selected threshold	p95
Training duration	109.7 minutes

F. 3.6 Sistem akisi

Onerilen is akisi bes adimdan olusmaktadır: normal verinin secilmesi, on isleme, autoencoder egitimi, validation error dagilimından esik secimi ve testte anomaly scoring. Raporun sonundaki Sekil 1 bu boru hattini gorsel olarak ozetlemektedir.

Bu sema, odevde istenen sistem mimarisi beklentisini karsilamak icin eklenmistir.

VIII. 4. ARA SONUCLAR

Bu ara raporda uretilen temel ciktilar; egitim/validation loss grafigi, validation reconstruction error histogrami, test error dagilimi, ROC curve, confusion matrix ve ornek reconstruction-residual görüntüleridir. Deney sonunda secilen p95 esiginde elde edilen metrikler asagidaki gibidir:

Metrik	Deger
AUROC	0.9108
Accuracy	0.7670
Precision	0.9743
Recall	0.7080
F1	0.8201
FPR	0.0560
Best epoch	37
Best validation loss	0.000745

Validation percentil esikleri:

percen	thresh	accur	precis	reca	fl	fpr	auro
tile	old	acy	ion	ll			c
95	0.001	0.767	0.974	0.70	0.82	0.0	0.91
	4		3	8	01	56	08
97	0.001	0.714	0.981	0.63	0.76	0.0	0.91
	6		3	07	79	36	08
99	0.002	0.593	0.997	0.45	0.62	0.0	0.91
	1		1	87	83	04	08

Sinif bazli reconstruction error ozeti:

class_	sample	patient	mean_reconstr	std_reconstr
name	_count	_count	uction_error	ction_error
CNV	250	178	0.002921	0.001294
DME	250	167	0.002592	0.001554
DRU	250	169	0.001317	0.000643
SEN				
NOR	250	171	0.000864	0.000292
MAL				

Veri bolme ozeti:

split_name	class_name	image_count	patient_count
train	NORMAL	40715	2747
val	NORMAL	10425	687
test	CNV	250	178
test	DME	250	167
test	DRUSEN	250	169
test	NORMAL	250	171

Sonuclar yalnızca tablo duzeyinde degil, yorum duzeyinde de anlamlidir. p95 esigi p97 ve p99'a gore daha yuksek recall ve F1 vermistir; bu nedenle ara rapor icin daha dengeli operasyon

noktasi olarak secilmistir. CNV ve DME siniflari NORMAL görüntülerden belirgin sekilde ayrisirken, DRUSEN sinifinin error dagilimi normale daha yakindir. Bu durum, bazı patolojilerin reconstruction tabanlı yaklasimlarda digerlerine gore daha zor ayristigini gostermektedir.

Rapor sonunda verilen Sekil 2, egitim egrisi, ROC performansi, error dagilimi ve reconstruction orneklerini bir araya getirerek ara sonuclarin gorsel ozetini sunmaktadir.

IX. 5. TARTISMA

Baseline model, gorece basit olmasina ragmen normal anatomi dagilimini ogrenerek patolojik siniflarin reconstruction error degerlerini yukseltebilmektedir. Bununla birlikte reconstruction tabanlı yontemlerin iyi bilinen bir siniri vardir: guclu decoder yapilari bazen anomalileri de fazla iyi yeniden uretebilir [4], [8]. Kermany veri kumesi image-level etiketler icerir; bu nedenle lokal lesion segmentasyonu icin dogrudan pixel-level ground truth bulunmamaktadır. Ayrica threshold seciminin precision-recall dengesi uzerinde guclu etkisi vardir. Bu nedenle tek bir metrik yerine percentile bazli karsilastirma tablosu korunmustur.

Hesaplama maliyeti de goz ardi edilemez. Egitim kosusu yerel ortamda uzun sayilabilecek bir surede tamamlanmistir ve bu durum veri yukleme ile on isleme hattinin da iyilestirme alani oldugunu gostermektedir. Dolayisiyla mevcut sistem klinik kullanimdan ziyade arastirma ve erken tarama mantiginda degerlendirilmelidir.

X. 6. GELECEK CALISMALAR

Final asamada standart autoencoder yerine VAE veya memory-augmented reconstruction modelleri denenebilir. Residual map kalitesi artirilabilir, daha yuksek giris cozunurlugu ile DRUSEN gibi zorlayici siniflarda ayristirma gucu test edilebilir ve image size, latent boyut ile threshold seciminin etkisi sistematik ablation calismalariyla incelenebilir.

XI. 7. SONUC


Bu ara rapor asamasinda, Kermany OCT verisi icin patient-level validation kullanan, yalnızca normal görüntülerle egitilen ve reconstruction error ile patolojik scan tespiti yapan tekrar uretilebilir bir baseline sistem kurulmustur. Gercek veri uzerinde elde edilen AUROC 0.9108 ve F1 0.8201 degerleri, projenin planlama asamasini gecip calisir ve savunulabilir bir noktaya geldigini gostermektedir. Final asamada hedef, bu baseline'i daha guclu anomaly detection yaklasimlariyla genisletmek ve sonucları karsilastirmali deneylerle desteklemektir.

XII. KAYNAKLAR


- [1] Kermany DS, Goldbaum M, Cai W, et al. Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell*. 2018;172(5):1122-1131. doi:10.1016/j.cell.2018.02.010
- [2] Kermany DS, Zhang K, Goldbaum M. Large Dataset of Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images. *Mendeley Data*. 2018;v3. doi:10.17632/rscbjbr9sj.3
- [3] Litjens G, Kooi T, Bejnordi BE, et al. A survey on deep learning in medical image analysis. *Med Image Anal*. 2017;42:60-88. doi:10.1016/j.media.2017.07.005
- [4] Schlegl T, Seebock P, Waldstein SM, Schmidt-Erfurth U, Langs G. Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery. *arXiv*. 2017. doi:10.48550/arXiv.1703.05921
- [5] Akcay S, Atapour-Abarghouei A, Breckon TP. GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training. *arXiv*. 2018. doi:10.48550/arXiv.1805.06725
- [6] Zavrtanik V, Kristan M, Skocaj D. DRAEM: A Discriminatively Trained Reconstruction Embedding for Surface Anomaly Detection. *ICCV*. 2021.
- [7] Seebock P, Orlando JJ, Schlegl T, et al. Exploiting Epistemic Uncertainty of Anatomy Segmentation for Anomaly Detection in Retinal OCT. *IEEE Trans Med Imaging*. 2019. doi:10.1109/TMI.2019.2919951
- [8] Zhou K, Li J, Luo W, et al. Proxy-bridged Image Reconstruction Network for Anomaly Detection in Medical Images. *arXiv*. 2021. doi:10.48550/arXiv.2110.01761
- [9] Luo Y, Ma Y, Yang Z. Multi-resolution auto-encoder for anomaly detection of retinal imaging. *Phys Eng Sci Med*. 2024;47(2):517-529. doi:10.1007/s13246-023-01381-x
- [10] Wang J, Li W, Chen Y, et al. Weakly supervised anomaly segmentation in retinal OCT images using an adversarial learning approach. *Biomed Opt Express*. 2021;12(8):4713-4729. doi:10.1364/BOE.426803

XIII. SEKİLLER

Retina OCT anomaly detection



Sekil 1. Önerilen retina OCT anomaly detection boru hattı.



Sekil 2. Eğitim, ROC, error dağılımı ve reconstruction çıktıları bir araya getiren özet görsel.