

Normal Retina OCT Görüntülerinden Öğrenilen Konvolüsyonel Autoencoder ile Patolojik Örneklerin Yeniden Oluşturma Hatası Tabanlı Tespiti

Reconstruction Error Based Detection of Pathological Retinal OCT Images Using a Convolutional Autoencoder Trained on Normal Samples

Koray Öztürk

Bilgisayar Mühendisliği
Eskişehir Osmangazi Üniversitesi
Eskişehir/Türkiye
korayoztuurk@gmail.com

Emir Alp İlhan

Bilgisayar Mühendisliği
Eskişehir Osmangazi Üniversitesi
Eskişehir/Türkiye
emiralpilhan@gmail.com

Özet

Bu çalışmada, retinal OCT görüntülerinde patolojik örnekleri etiketlenmiş patoloji sınıflarıyla doğrudan öğrenmek yerine, yalnızca normal örneklerden öğrenilen bir konvolüsyonel autoencoder ile yeniden oluşturma hatasına (reconstruction error) dayalı anormali tespiti yaklaşımı geliştirilmiştir. Kermany OCT2017 veri kümesindeki 'train/NORMAL' görüntüleri hasta düzeyinde eğitim ve doğrulama alt kümelerine ayrılmış, model yalnızca normal anatominin dağılımını öğrenmiştir. Test aşamasında NORMAL, CNV, DME ve DRUSEN görüntüleri yeniden oluşturma hatasına göre puanlanmış ve doğrulama kümesindeki normal hata dağılımından elde edilen persentil eşikleri ile ikili karar üretilmiştir. Bu ara rapor sürümünde temel model 128x128 gri tonlamalı B-kesitleri üzerinde eğitilmiş, AUROC ana ölçüt olarak alınmış; doğruluk, kesinlik, duyarlılık, F1 ve yanlış pozitif oranı da raporlanmıştır. OCT2017 veri kümesi üzerinde yapılan deneylerde seçilen p95 eşğinde AUROC 0.9108 ve F1 0.8201 elde edilmiştir.

Abstract

This study investigates reconstruction-error-based anomaly detection for retinal OCT images using a convolutional autoencoder trained only on normal samples. Instead of learning a supervised pathology classifier, the model learns the appearance distribution of healthy retinal anatomy from the Kermany OCT2017 dataset. The training split uses only normal scans and a patient-level validation split is used to estimate operating thresholds from normal reconstruction-error percentiles. During testing, NORMAL, CNV, DME, and DRUSEN scans are scored according to reconstruction error, and anomaly decisions are produced with validation-derived thresholds. On the real OCT2017 experiment, the selected p95 operating point reaches AUROC 0.9108 and F1-score 0.8201. These findings indicate that a normal-only autoencoder can serve as a meaningful early baseline for retinal anomaly screening.

Anahtar Kelimeler / Keywords - retinal OCT, anormali tespiti, autoencoder, yeniden oluşturma hatası, tıbbi görüntüleme, derin öğrenme

I. Giriş

Retinal hastalıkların erken tespiti, geri dönüşü olmayan görme kaybını azaltmak için kritik önemdedir. Optik koherens tomografi (OCT), retina tabakalarını yüksek çözünürlükte gösterebildiği için klinik pratikte sık kullanılan bir görüntüleme yöntemidir. Ancak OCT verisinin elle yorumlanması zaman alıcı olduğu gibi, geniş tarama programlarında yüksek uzman emeği gerektirir [1]. Son yıllarda derin öğrenme tabanlı denetimli modeller OCT sınıflandırmasında güçlü sonuçlar vermiş olsa da, bunlar genellikle her patoloji için etiketli veri gerektirir [1], [3]. Bu durum, daha önce görülmemiş veya yeterince temsil edilmeyen anomalilerin tespitini zorlaştırır.

Bu projede problem, normal anatominin öğrenilmesi ve ondan sapmaların yeniden oluşturma hatası ile yakalanması olarak ele alınmıştır. Ara rapor kapsamındaki amacımız, yalnızca normal retina OCT görüntüleri ile eğitilen bir konvolüsyonel autoencoder modelinin patolojik test görüntülerini anlamlı biçimde ayrıştırabildiğini gösteren, tekrar üretilebilir bir temel model kurmaktır. Bu çalışmada, hasta düzeyinde doğrulama, doğrulama dağılımından türetilen eşik seçimi ve gerçek OCT verisiyle uçtan uca çalışan bir deney hattını içeren tekrar üretilebilir bir temel sistem sunulmuştur.

II. İLGİLİ ÇALIŞMALAR

OCT alanında derin öğrenme tabanlı hastalık sınıflandırması için en çok atıf alan çalışmalardan biri Kermany ve ark. tarafından sunulan Cell 2018 makalesidir [1]. Bu çalışma, aynı zamanda bu projede kullanılan halka açık OCT veri kümesinin temellerini de oluşturmaktadır [2]. Literatürde bunun devamında çok sayıda denetimli retinal hastalık tespit modeli önerilmiş ve OCT'nin otomatik analiz için uygunluğu güçlü biçimde ortaya konmuştur [3].

Anormali tespiti literatüründe ise normal veriyle eğitim yapıp anomalileri dağılım dışı örnekler olarak ele alan yeniden oluşturma temelli ve adversarial (çekişmeli) yöntemler ön plana çıkmıştır. AnoGAN [4] ve GANomaly [5] gibi yaklaşımlar normal dağılımı modelleme mantığını

sistemati leştirmiştir. DRAEM [6] ve ProxyAno [8] ise yeniden oluřturma tabanlı yapıların daha ayırt edici hale gelmesine odaklanmıştır. Retinal OCT  zelinde Seebock ve ark. [7], Luo ve ark. [9] ve Wang ve ark. [10] gibi  alıřmalar bu alanın artık yalnızca genel ama lı anormali tespiti deęil, retina anatomisine  zel     mler de gerektirdięini g stermektedir.

Kim ne yapmıř ve bu proje neyi farklı yapıyor sorusunu daha a ık g stermek i in Tablo 1 verilmiřtir.

Tablo 1. İlgili  alıřmalar ve bu projeden farkları.

�alıřma	Odak	Fark
Kermany et al. [1]	Denetimli OCT sınıflandırması	Patoloji etiketleri gerektirir; bizim yaklařımımız yalnızca normal g�r�nt�lerle anormali tespiti yapar.
AnoGAN [4]	GAN tabanlı anormali tespiti	Genel ama�lı anormali tespiti yaklařımıdır; retinal OCT'ye �zg� deęildir.
Seebock et al. [7]	Belirsizlik tabanlı OCT anormali tespiti	Doęrudan rekonstr�ksiyon hatası yerine anatomi segmentasyonu belirsizlięi kullanır.
Luo et al. [9]	�ok ����n�rl�kl� retinal autoencoder	Daha geliřmiř retinal anormali modeli �nerir; bizim �alıřmamız ise daha sade ve tekrar �retilabilir bir temel model sunar.
Wang et al. [10]	Zayıf denetimli retinal OCT anormali b�l�tleme	Anormali b�lgelerinin konumunu vurgular; bizim yaklařımımız g�r�nt� d�zeyinde puanlama yapan daha sade bir temel modeldir.
Bu proje	Normal �rneklerle OCT anormali puanlaması	Hasta d�zeyinde doęrulama b�lmesi ve ger�ek OCT2017 verisi �zerinde persentil tabanlı eřik se�imi i�erir.

III. Y NTEM

A. Veri k mesi ve b lme stratejisi

 alıřmada Kermany OCT2017 veri k mesinin 'train' ve 'test' verileri kullanılmıřtır [2]. Eęitimde yalnızca 'train/NORMAL' altındaki g r nt ler kullanılmıřtır. Doęrulama b lmesi g r nt  d zeyinde deęil hasta d zeyinde yapılmıřtır; b ylece aynı hastaya ait g r nt ler eęitim ve doęrulama alt k melerine aynı anda d řmemiřtir. Hasta kimlikleri, veri k mesindeki dosya adlarında yer alan 'hastalık-hastaID-g r nt No' yapısından ayrıştırılmıřtır. Test ařamasında 'test/NORMAL', 'test/CNV', 'test/DME' ve 'test/DRUSEN' g r nt leri birlikte deęerlendirilmiř, NORMAL sınıfı 0 ve dięer t m sınıflar anormali etiketi 1 olarak ele alınmıřtır.

B.  n iřleme

T m g r nt ler tek kanallı gri tonlamaya d n řt r lm ř, '128x128' boyutuna yeniden  rneklenmiř ve '[0, 1]' aralıęına normalize edilmiřtir. Bu ara s r mde yoęun veri artırma uygulanmamıřtır; amacımız  nce sade ve tekrarlanabilir bir temel model kurmaktır.

C. Model mimarisi

Model, d rt ařamalı bir konvol syonel autoencoder yapısından oluřmaktadır. Encoder kısmı '1->32->64->128->256' kanal ge iřleri ve max-pooling adımlarıyla g r nt y  sıkıřtırırken, ara gizil temsil '128' boyutlu bir vekt re indirgenmiřtir. Decoder kısmı transpose convolution blokları ile g r nt y  tekrar '128x128' boyutuna tařımaktadır.  ıkıř katmanında sigmoid kullanılarak normalize pikseller  zerinde yeniden oluřturma  ıktısı  retilmiřtir.

D. Eęitim ve eřikleme

Model 'Adam' optimizer'ı ve 'MSE' reconstruction loss ile eęitilmiřtir. En fazla '40' epoch ve '8' patience deęerli early stopping kullanılmıřtır. Doęrulama ařamasında yalnızca normal  rneklerin yeniden oluřturma hatası daęılımı incelenmiř; p95, p97 ve p99 eřikleri hesaplanmıřtır. Ana operasyon noktası olarak p95 se ilmiřtir. B ylece eřik se iminde test verisi kullanılmamıř ve data leakage engellenmiřtir.

E. Deęerlendirme  l  tleri ve deney kurulumu


Ana bařarı  l  t  olarak AUROC se ilmiřtir;   nk  anormali tespiti senaryosunda eřikten bağımsız ayrıştırma g c n  yansıtır. Bunun yanında doęruluk (accuracy), kesinlik (precision), duyarlılık (recall), F1 ve yanlış pozitif oranı (false positive rate, FPR) de raporlanmıřtır. Kesinlik ve duyarlılık birlikte yorumlanmıř, F1 ise dengeli operasyon noktası se iminde kullanılmıřtır. Ger ek deney kořusu yaklaşık 109.7 dakika s rm ř ve en iyi doęrulama sonucu 37. epoch'ta elde edilmiřtir. Deney, NVIDIA GeForce RTX 4060 Laptop GPU i eren yerel bir PyTorch ortamında y r t lm řtir. Deney kurulumu Tablo 2'de  zetlenmiřtir.

Tablo 2. Deney kurulumu ve temel hiperparametreler.

Ayar	Deęer
Eęitim verisi	40715 NORMAL g�r�nt�
Doęrulama verisi	10425 NORMAL g�r�nt�
Test verisi	1000 g�r�nt�
Giriř boyutu	128x128 gri seviye
Latent boyut	128
Optimizasyon	Adam, lr=0.001
Maks. epoch / patience	40 / 8
Se�ilen eřik	p95
Eęitim s�resi	109.7 dakika

F. Sistem akışı

Önerilen iş akışı beş adımdan oluşmaktadır: normal verinin seçilmesi, ön işleme, autoencoder eğitimi, doğrulama hata dağılımından eşik seçimi ve testte anomali puanlaması. Şekil 1, önerilen sistemin iş akışını özetlemektedir.



Şekil 1. Önerilen retina OCT anomali tespit boru hattı.

IV. ARA SONUÇLAR

Bu ara raporda üretilen temel çıktılar; eğitim ve doğrulama kayıp grafiği, doğrulama yeniden oluşturma hatası histogramı, test hata dağılımı, ROC eğrisi, karışıklık matrisi ve örnek yeniden oluşturma-kalıntı görüntüleridir. Deney sonunda seçilen p95 eşğinde elde edilen metrikler aşağıdaki gibidir:

Metrik	Değer
AUROC	0.9108
Doğruluk	0.7670
Kesinlik	0.9743
Duyarlılık	0.7080
F1	0.8201
FPR	0.0560
En iyi epoch	37
En iyi doğrulama kaybı	0.000745

Doğrulama persentil eşikleri:

Persentil	Eşik	Doğruluk	Kesinlik	Duyarlılık	F1	FP R	AUROC
95	0.0014	0.767	0.9743	0.708	0.8201	0.056	0.9108
97	0.0016	0.714	0.9813	0.6307	0.7679	0.036	0.9108
99	0.0021	0.593	0.9971	0.4587	0.6283	0.004	0.9108

Sınıf bazlı yeniden oluşturma hatası özeti:


Sınıf	Örnek	Hasta	Ort. hata	Std. sapma
CNV	250	178	0.002921	0.001294
DME	250	167	0.002592	0.001554
DRUSEN	250	169	0.001317	0.000643
NORMAL	250	171	0.000864	0.000292

Veri bölme özeti:

Bölme	Sınıf	Görüntü	Hasta
Eğitim	NORMAL	40715	2747
Doğrulama	NORMAL	10425	687
Test	CNV	250	178
Test	DME	250	167
Test	DRUSEN	250	169
Test	NORMAL	250	171

Sonuçlar yorum düzeyinde de anlamlıdır. p95 eşiği p97 ve p99'a göre daha yüksek duyarlılık ve F1 vermiştir; bu nedenle ara rapor için daha dengeli operasyon noktası olarak seçilmiştir. CNV ve DME sınıfları NORMAL görüntülerden belirgin şekilde ayrışırken, DRUSEN sınıfının hata dağılımı normale daha yakındır. Bu durum, bazı patolojilerin yeniden oluşturma tabanlı yaklaşımlarda diğerlerine göre daha zor ayrıştığını göstermektedir.

Şekil 2'de eğitim eğrisi, ROC performansı, hata dağılımı ve yeniden oluşturma örnekleri bir arada verilerek ara sonuçlar görsel olarak özetlenmiştir.



Şekil 2. Eğitim eğrisi, ROC performansı, hata dağılımı ve yeniden oluşturma örneklerinin özet görseli.

V. TARTIŞMA

Temel model, görece basit olmasına rağmen normal anatomi dağılımını öğrenerek patolojik sınıfların yeniden oluşturma hatalarını yükseltebilmektedir. Bununla birlikte yeniden oluşturma tabanlı yöntemlerin iyi bilinen bir sınırı vardır: güçlü çözücü yapıları bazen anomalileri de fazla iyi yeniden üretebilir [4], [8]. Kermany veri kümesi görüntü düzeyinde etiketler içerir; bu nedenle yerel lezyon bölütlemesi için doğrudan piksel düzeyinde gerçek etiket bulunmamaktadır. Ayrıca eşik seçiminin kesinlik-duyarlılık dengesi üzerinde güçlü etkisi vardır. Bu nedenle tek bir metrik yerine persentil bazlı karşılaştırma tablosu korunmuştur.

Hesaplama maliyeti de göz ardı edilemez. Eğitim koşusu yerel ortamda uzun sayılabilecek bir sürede tamamlanmıştır ve bu durum veri yükleme ile ön işleme hattının da iyileştirme alanı olduğunu göstermektedir. Dolayısıyla mevcut sistem klinik kullanımdan ziyade araştırma ve erken tarama mantığında değerlendirilmelidir.

VI. GELECEK ÇALIŞMALAR

Final aşamada ilk geliştirme eksen, mimari seviyesinde daha güçlü yeniden oluşturma modellerinin denenmesi olacaktır. Standart autoencoder yerine VAE, skip-connection içeren daha derin yapılar veya bellek destekli yeniden oluşturma modelleri uygulanabilir. Buna ek olarak MSE yanında L1 ve SSIM tabanlı kayıplar deneyerek yeniden oluşturma kalitesi ile anomali duyarlılığı arasındaki denge incelenecektir.

İkinci eksen, veri ve deney tasarımı odaklanacaktır. Daha yüksek giriş çözünürlüğü ile özellikle DRUSEN gibi daha zor ayrıştırılan sınıfların daha iyi temsil edilip edilmediği test edilecek; gizil boyut, mini-batch boyutu (batch size), eşik seçimi ve görüntü boyutu gibi hiperparametreler sistematik bir ablasyon çalışması ile karşılaştırılacaktır.

Üçüncü eksen, yorumlanabilirlik ve karşılaştırmalı değerlendirmedir. Kalıntı (residual) haritaları ve hata haritası görselleştirmeleri kullanılarak modelin hangi bölgelerde sapma ürettiği incelenecek; en iyi ve en kötü örnekler ayrıca tartışılacaktır. Bunun yanında veri yükleme hattı ve eğitim süresi optimize edilerek mevcut temel model en az bir geliştirilmiş varyantla AUROC, F1, duyarlılık ve FPR açısından karşılaştırılacaktır.

VII. SONUÇ

Bu ara rapor aşamasında, Kermany OCT verisi için hasta düzeyinde doğrulama kullanan, yalnızca normal görüntülerle eğitilen ve yeniden oluşturma hatası ile patolojik OCT örneklerini tespit eden tekrar üretilebilir bir temel sistem kurulmuştur. OCT2017 veri kümesi üzerinde elde edilen AUROC 0.9108 ve F1 0.8201 değerleri, yaklaşımın umut verici olduğunu göstermektedir. Final aşamada hedef, bu temel modeli daha güçlü anomali tespiti yaklaşımlarıyla genişletmek ve sonuçları karşılaştırmalı deneylerle desteklemektir.

VIII. KAYNAKLAR

- [1] D. S. Kermany et al., "Identifying medical diagnoses and treatable diseases by image-based deep learning," *Cell*, vol. 172, no. 5, pp. 1122-1131.e9, 2018, doi: 10.1016/j.cell.2018.02.010.
- [2] D. S. Kermany, K. Zhang, and M. Goldbaum, "Large dataset of labeled optical coherence tomography (OCT) and chest X-ray images," *Mendeley Data*, ver. 3, 2018, doi: 10.17632/rscbjbr9sj.3.
- [3] G. Litjens et al., "A survey on deep learning in medical image analysis," *Med. Image Anal.*, vol. 42, pp. 60-88, 2017, doi: 10.1016/j.media.2017.07.005.
- [4] T. Schlegl, P. Seebock, S. M. Waldstein, U. Schmidt-Erfurth, and G. Langs, "Unsupervised anomaly detection with generative adversarial networks to guide marker discovery," *arXiv:1703.05921*, 2017, doi: 10.48550/arXiv.1703.05921.
- [5] S. Akcay, A. Atapour-Abarghouei, and T. P. Breckon, "GANomaly: Semi-supervised anomaly detection via adversarial training," in *Proc. Asian Conf. Comput. Vis. (ACCV)*, pp. 622-637, 2018, doi: 10.1007/978-3-030-20893-6_39.

[6] V. Zavrtanik, M. Kristan, and D. Skocaj, "DRAEM - A discriminatively trained reconstruction embedding for surface anomaly detection," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV)*, pp. 8330-8339, 2021.

[7] P. Seebock et al., "Exploiting epistemic uncertainty of anatomy segmentation for anomaly detection in retinal OCT," *IEEE Trans. Med. Imaging*, vol. 39, no. 1, pp. 87-98, 2020, doi: 10.1109/TMI.2019.2919951.

[8] K. Zhou et al., "Proxy-bridged image reconstruction network for anomaly detection in medical images," *IEEE Trans. Med. Imaging*, vol. 41, no. 3, pp. 582-594, 2022, doi: 10.1109/TMI.2021.3118223.

[9] Y. Luo, Y. Ma, and Z. Yang, "Multi-resolution auto-encoder for anomaly detection of retinal imaging," *Phys. Eng. Sci. Med.*, vol. 47, no. 2, pp. 517-529, 2024, doi: 10.1007/s13246-023-01381-x.

[10] J. Wang, W. Li, Y. Chen, et al., "Weakly supervised anomaly segmentation in retinal OCT images using an adversarial learning approach," *Biomed. Opt. Express*, vol. 12, no. 8, pp. 4713-4729, 2021, doi: 10.1364/BOE.426803.